API Specification (REST) — MVP
AI-сервис генерации презентаций для российских вузов (B2B2C)

Версия: 1.0
Дата: 28.02.2026
Команда: Ангелы Бизнеса

Назначение: зафиксировать REST-контракты MVP (Brief Normalize, Generate, Edit, Get, Export), единый формат ошибок, правила идемпотентности/ретраев и лимиты.

Оглавление

0. Общие положения 4
Base URL 4
Аутентификация и авторизация 4
Заголовки 4
Ограничения и лимиты (MVP defaults) 4
Retry policy 4
Единый формат ошибок 4
Коды ошибок 4
1. Эндпоинты MVP 5
1.1 POST /brief/normalize 5
Назначение 5
Request 5
Response 5
Идемпотентность / ретраи 6
Лимиты 6
Ошибки 6
1.2 POST /deck/generate 6
Назначение 6
Request 6
Response 7
Идемпотентность / ретраи 7
Лимиты 7
Ошибки 7
1.3 POST /deck/{id}/edit 7
Назначение 7
Request 7
Response 8
Идемпотентность / ретраи 8
Лимиты 8
Ошибки 8
1.4 GET /deck/{id} 8
Назначение 8

Request 8
Response 8
Идемпотентность / ретраи 9
Лимиты 9
Ошибки 9
1.5 POST /deck/{id}/export 9
Назначение 9
Request 9
Response 10
202 Accepted (job created): 10
200 OK (cached result): 10
Идемпотентность / ретраи 10
Лимиты 10
Ошибки 10
2. Примечания по реализации (MVP) 10
2.1 Хранение артефактов пайплайна 10
2.2 Audit log 10

0. Общие положения

Base URL

/api/v1

Аутентификация и авторизация

Компонент	Описание
SSO (OIDC/SAML)	UI получает JWT/Session-cookie и обращается к Backend.
RBAC + org_unit	Роли Student/Teacher/Admin/Buyer + ограничения по орг-единицам.

Заголовки

Header	Назначение
Authorization	Bearer <token> (или cookie)
X-Tenant-Id	<tenant_id> (если не выводится из токена)
Idempotency-Key	<uuid> для POST, где требуется идемпотентность
X-Request-Id	<uuid> корреляция логов (опционально)

Ограничения и лимиты (MVP defaults)

Лимит	Значение
Размер источников (MVP)	до 10 MB через API (иначе отдельный upload сервис)
Макс. слайдов	slide_count ≤ 15
Rate limit edit	≤ 30 операций/мин/пользователь
Параллельные generation_run	≤ 2 активных run на пользователя
TTL download_url	15 минут (signed URL)

Retry policy

- Коды для ретрая: 429/503/504
- Backoff: exponential backoff 1s,2s,4s + jitter
- Безопасность ретрая: POST с Idempotency-Key должны возвращать тот же результат в рамках TTL (реком. 24 часа).

Единый формат ошибок

```
{
  "error": {
    "code": "STRING_CODE",
    "message": "human readable",
    "details": {"any":"json"},
    "request_id": "uuid"
  }
}
```

Коды ошибок

HTTP	Code	Описание
400	INVALID_REQUEST	Невалидный JSON/схема/обязательные поля

401	UNAUTHORIZED	Нет аутентификации
403	FORBIDDEN	Нет прав (RBAC/org_unit/tenant)
404	NOT_FOUND	Ресурс не найден
409	CONFLICT	Конфликт версий/base_version_id
413	PAYLOAD_TOO_LARGE	Слишком большой payload
422	SCHEMA_VALIDATION_FAILED	Внутренняя ошибка: выход LLM не проходит схему
429	RATE_LIMITED	Превышены лимиты
500	INTERNAL_ERROR	Неожиданная ошибка
503	LLM_UNAVAILABLE / RENDERER_UNAVAILABLE	Сервисы недоступны
504	TIMEOUT	Таймаут

1. Эндпоинты MVP

1.1 POST /brief/normalize

Назначение

Нормализует сырой бриф в канонический brief_v1 (P0) и выявляет missing_info/clarifying_questions.

Request

```
{
  "lang": "ru",
  "raw_brief": "string",
  "tenant_brand": {
    "template_id": "string",
    "brand_lock_level": "strict|medium|low",
    "palette": {"primary":"#","secondary":"#","accent":"#","bg":"#","text":"#"},
    "fonts": {"primary":"string","secondary":"string"}
  },
  "sources_manifest": [
    {"source_ref":"s1","type":"text|table|link","title":"string","content":"string","uri":null}
  ]
}
```

Response

```
{
  "brief_v1": {
    "brief": {
      "topic": "string",
      "goal": "string",
      "audience": {"who":"string","level":"string","pain_points":["string"]},
      "context": "string",
      "key_messages": ["string"],
      "call_to_action": "string",
      "constraints": {
        "slide_count": 10,
        "time_minutes": 5,
        "language": "ru",
        "tone": "string",
```

```
        "must_include": ["string"],
        "must_avoid": ["string"]
      },
      "brand": {"template_id":"string","brand_lock_level":"strict"},
      "data_inputs": [{"type":"text|table|link|none","description":"string","ref":"s1"}],
      "assumptions": ["assumed: ..."]
    },
    "missing_info": ["string"],
    "clarifying_questions": ["string"],
    "risks": ["string"]
  }
}
```

Идемпотентность / ретраи

Рекомендуется Idempotency-Key. При одинаковом raw_brief + tenant_brand + sources_manifest и одинаковом ключе — вернуть тот же brief_v1.

Лимиты

Размер sources_manifest в пределах лимита payload; content без больших бинарных файлов.

Ошибки

- 400 INVALID_REQUEST
- 413 PAYLOAD_TOO_LARGE
- 401/403
- 429
- 503 LLM_UNAVAILABLE

1.2 POST /deck/generate

Назначение

Запускает генерацию презентации по пайплайну P0–P7: normalize→storyline→blueprint→copy→QA→render_spec.

Request

```
{
  "lang": "ru",
  "input": {
    "raw_brief": "string",
    "brief_v1": null,
    "clarifier_answers": {},
    "sources_manifest": [
      {"source_ref":"s1","type":"text|table|link","title":"string","content":"string","uri":null}
    ]
  },
  "generation_config": {
    "mode": "student|teacher|admin",
    "strict_sources_only": true,
    "max_slide_count": 15,
    "target_time_minutes": 5
  },
  "tenant_brand": {
    "template_id": "string",
```

```
    "brand_lock_level": "strict|medium|low"
  }
}
```

Response

```
{
  "deck_id": "deck_123",
  "run_id": "run_456",
  "status": "queued|running",
  "poll": {
    "deck_url": "/api/v1/deck/deck_123",
    "recommended_interval_ms": 1500
  }
}
```

Идемпотентность / ретраи

Обязательно Idempotency-Key. Повтор с тем же ключом возвращает тот же deck_id/run_id/status. TTL ключа: 24 часа (рекоменд.).

Лимиты

max_slide_count ≤ 15; concurrent runs ≤ 2 per user; payload size ≤ 10MB.

Ошибки

- 400 INVALID_REQUEST
- 403 FORBIDDEN
- 409 CONFLICT
- 422 SCHEMA_VALIDATION_FAILED
- 429 RATE_LIMITED
- 503 LLM_UNAVAILABLE

1.3 POST /deck/{id}/edit

Назначение

Частичная регенерация (P8): точечная правка одного слайда/блока с контролем версий (base_version_id).

Request

```
{
  "base_version_id": "v1",
  "operation": "rewrite_slide|add_slide|delete_slide|change_visual",
  "target": {
    "slide_no": 5,
    "block": "title|bullets|speaker_notes|visual|all"
  },
  "instruction": "Сократи буллеты, сделай проще, добавь 1 пример (без новых фактов).",
  "constraints": {
    "max_bullets": 5,
    "max_words_per_bullet": 12
  }
}
```

Response

```
{
  "deck_id": "deck_123",
  "old_version_id": "v1",
  "new_version_id": "v2",
  "patch": {
    "slide_no": 5,
    "title": null,
    "bullets_replace": ["...","...","..."],
    "speaker_notes": null,
    "visual_patch": null
  },
  "diff_summary": "Буллеты укорочены, терминология унифицирована.",
  "qa_patch": {
    "issues": [{"severity":"low","problem":"...","fix_suggestion":"..."}],
    "score_delta": 1
  }
}
```

Идемпотентность / ретраи

Рекомендуется Idempotency-Key (UI ретраи). base_version_id обязателен для защиты от гонок.

Лимиты

rate limit edit ≤30/min/user; bullets ≤5; words per bullet ≤12.

Ошибки

- 404 NOT_FOUND
- 409 CONFLICT
- 403 FORBIDDEN
- 400 INVALID_REQUEST
- 422 SCHEMA_VALIDATION_FAILED
- 429
- 503 LLM_UNAVAILABLE

1.4 GET /deck/{id}

Назначение

Возвращает deck, статусы генерации/экспорта, версии и ссылки на артефакты.

Request

```
(query params) version_id (optional), include=slides|qa|render_spec|exports
```

Response

```
{
  "deck": {
    "deck_id": "deck_123",
    "tenant_id": "t1",
    "owner_user_id": "u1",
    "current_version_id": "v2",
    "status": "draft|ready|exporting|failed",
    "meta": {
```

```
      "lang": "ru",
      "template_id": "tpl_01",
      "brand_lock_level": "strict",
      "created_at": "2026-02-28T10:00:00Z",
      "updated_at": "2026-02-28T10:05:00Z"
    },
    "slides": [
      {"slide_no":1,"title":"...","bullets":["..."],"speaker_notes":"..."}
    ],
    "qa_report": {
      "score_total": 16,
      "issues": [{"severity":"medium","slide_no":3,"problem":"..."}],
      "needs_user_input": []
    },
    "render_spec": {"ref":"s3://.../render_spec.json"},
    "exports": [

{"export_id":"e1","format":"pptx","status":"completed","download_url":"https://...","expires_at":"
..."}
    ]
  }
}
```


Идемпотентность / ретраи

GET идемпотентен по определению.

Лимиты

include=render_spec может быть тяжёлым — по умолчанию отдавать ref; полный spec по ссылке.

Ошибки

- 404 NOT_FOUND
- 403 FORBIDDEN

1.5 POST /deck/{id}/export

Назначение

Создаёт ExportJob и запускает Renderer (PPTX/PDF). Кэш-идемпотентность по (deck_id, version_id, format, options_hash).

Request

```
{
  "version_id": "v2",
  "format": "pptx|pdf",
  "options": {
    "include_speaker_notes": true,
    "compress_images": true
  }
}
```

Response

202 Accepted (job created):

```
{
  "export_id": "exp_789",
  "deck_id": "deck_123",
  "version_id": "v2",
  "format": "pptx",
  "status": "queued|running",
  "poll": {
    "deck_url": "/api/v1/deck/deck_123",
    "recommended_interval_ms": 1500
  }
}
```

200 OK (cached result):

```
{
  "export_id": "exp_789",
  "status": "completed",
  "download_url": "https://signed-url",
  "expires_at": "2026-02-28T10:30:00Z"
}
```

Идемпотентность / ретраи

Обязательно Idempotency-Key. Если экспорт уже существует для версии — вернуть готовый результат.

Лимиты

export rate limit ≤10/min/user; slide_count ≤15; download_url TTL 15 минут.

Ошибки

- 409 CONFLICT (quality gate)
- 503 RENDERER_UNAVAILABLE
- 504 TIMEOUT
- 422 (render_spec invalid/missing)
- 429 RATE_LIMITED
- 400 INVALID_REQUEST

2. Примечания по реализации (MVP)

2.1 Хранение артефактов пайплайна

В GenerationRun (DB) сохранять: promptset_version, prompt_versions[], model_ids[], input_hash и refs на brief_v1/storyline/blueprint/slides/qa/render_spec в Object Storage (S3/MinIO) — для воспроизводимости и аудита.

2.2 Audit log

Фиксировать события: generate_start/finish, edit, export_start/finish, template_update, role_change. Audit log — append-only (Postgres + опционально write-once storage).

Связанные документы: PRD, SRS, System Architecture, Prompt Architecture, QA Plan.