Prompt Architecture — часть системного дизайна
AI-сервис генерации презентаций для российских вузов (B2B2C)

Версия: 1.1
Дата: 28.02.2026
Команда: Ангелы Бизнеса

Назначение: описать LLM-пайплайн P0–P8, контракты JSON, guardrails, HITL, частичную регенерацию и rubric качества, а также предоставить реальные тексты промптов для внедрения в Orchestrator/LLM Gateway.

Оглавление

1. Обзор prompt-архитектуры 4
   1.1 Входы пайплайна 4
   1.2 Выходы пайплайна 4
   1.3 Ключевой принцип доверия 4
2. Таблица Prompt steps 4
3. JSON-контракты шагов (минимум для MVP) 5
   P0 brief_v1 5
   P6 qa_report 5
   P7 render_spec_v1 5
   P8 slide_patch 6
4. Guardrails 6
   4.1 Anti-hallucination (факты/цифры) 6
   4.2 Style locks / brand-lock 6
   4.3 Length limits / readability 6
   4.4 Safety & privacy guardrails 6
5. Human-in-the-loop (HITL) 7
6. Частичная регенерация (per slide / per block) 7
   6.1 Локальный контекст для P8 7
   6.2 Стратегии 7
   6.3 Контроль дрейфа 7
7. Автоматическая оценка качества (Rubric) 7
   7.1 Правила R1–R10 (0/1/2) 7
   7.2 Как считается 8
   7.3 Quality gate 8
8. Операционные детали (Orchestrator + LLM Gateway) 8
Приложение A. Реальные тексты промптов (P0–P8) 9
   P0 — Brief Normalizer 9
      System 9
      Developer 9
      User 9
   P1 — Clarifier 9
      System 9

Developer 9
User 9
P2 — Storyline Planner 9
System 9
Developer 9
User 9
P3 — Slide Blueprint 10
System 10
Developer 10
User 10
P4 — Copywriter & Notes 10
System 10
Developer 10
User 10
P5 — Visual Planner 10
System 10
Developer 10
User 10
P6 — QA & Consistency Fix 10
System 10
Developer 11
User 11
P7 — Renderer Spec Builder 11
System 11
Developer 11
User 11
P8 — Targeted Regen (Edit Loop) 11
System 11
Developer 11
User 11

1. Обзор prompt-архитектуры

Prompt-архитектура обеспечивает воспроизводимую генерацию брендированных академических презентаций с контролем качества, стоимости и рисков (галлюцинации/стиль/комплаенс). Она поддерживает частичную регенерацию и формирует прозрачные артефакты для разработки и аудита.

1.1 Входы пайплайна

- raw_brief (тема/цель/аудитория/формат/ограничения)
- sources[] (текст/документы/таблицы), разрешённые для фактов
- tenant_brand (brand tokens + шаблоны/макеты + правила brand-lock)
- context (роль пользователя, org_unit, язык, целевой формат экспорта)

1.2 Выходы пайплайна

- deck (структура + слайды + speaker notes + пометки NEEDS_SOURCE)
- visual_plan (визуальная концепция, графики/плейсхолдеры)
- render_spec (строго структурированный JSON для Renderer)
- qa_report (issues, score, needs_user_input)

1.3 Ключевой принцип доверия

LLM не является источником истины: факты/цифры должны быть извлечены из sources, либо помечены NEEDS_SOURCE, либо вынесены в clarifying_questions.

2. Таблица Prompt steps

Step	Название	Назначение	Вход	Выход	Техника prompting
P0	Brief Normalizer	Канонизировать brief, выявить пробелы	raw_brief, tenant_brand	brief_v1	Role + structured extraction, defaults as assumed
P1	Clarifier	До 7 вопросов + дефолты	brief_v1	clarifier_pack	Minimal questions, priority, default+confirm
P2	Storyline Planner	2–3 альтернативы + выбор	brief_v1 (+answers)	storyline_v1	Multi-option + scoring rubric
P3	Slide Blueprint	План слайдов: цель/тезисы/визуал	storyline_v1, brief_v1	blueprint_v1	Template-driven schema, length limits
P4	Copywriter & Notes	Финальный текст + notes + термины	blueprint_v1	slides_v1 + terms_dict	Rewrite with constraints + glossary
P5	Visual Planner	План визуалов + промпты ассетов	slides_v1, sources	visual_plan_v1	Visual mapping + placeholders

P6	QA & Consistency Fix	Rubric + автофиксы + needs_input	slides_v1, brief_v1	qa_report + slides_v2	Self-critique checklist + constrained fixes
P7	Renderer Spec Builder	render_spec для PPTX	slides_v2, visual_plan, tenant_brand	render_spec_v1	Strict JSON schema + layout mapping
P8	Targeted Regen	Частичная регенерация per slide/block	deck_id, slide_context, instruction	slide_patch + qa_patch	Local context retrieval + diff patch

3. JSON-контракты шагов (минимум для MVP)

Контракты валидируются JSON Schema в Orchestrator/LLM Gateway. В репозитории рекомендуется хранить как /schemas/Px.schema.json.

P0 brief_v1

```
{
  "brief":
{"topic":"string","goal":"string","audience":{"who":"string","level":"string","pain_points":["stri
ng"]},
            "context":"string","key_messages":["string"],"call_to_action":"string",

"constraints":{"slide_count":"number|null","time_minutes":"number|null","language":"string","tone"
:"string",
                           "must_include":["string"],"must_avoid":["string"]},
            "brand":{"template_id":"string","brand_lock_level":"strict|medium|low"},

"data_inputs":[{"type":"text|table|link|none","description":"string","ref":"string|null"}],
            "assumptions":["string"]},
  "missing_info":["string"],
  "clarifying_questions":["string"],
  "risks":["string"]
}
```

P6 qa_report

```
{
  "score":{"total":0,"by_rule":[{"rule":"R1..R10","score":0,"notes":"string"}]},

"issues":[{"severity":"low|medium|high","slide_no":1,"problem":"string","fix_suggestion":"string"}
],

"needs_user_input":[{"slide_no":1,"question":"string","why":"string","suggested_default":"string|n
ull"}],
  "fixed_slides":[{"slide_no":1,"title":"string","bullets":["string"],"speaker_notes":"string"}]
}
```

P7 render_spec_v1

```
{

"theme":{"font_primary":"string","font_secondary":"string","palette":{"primary":"string","secondar
```

```
y":"string","accent":"string","bg":"string","text":"string"}},
  "deck_meta":{"tenant_id":"string","template_id":"string","language":"string"},
  "slides":[{"slide_no":1,"layout_id":"TITLE|TITLE_BULLETS|TWO_COL|CHART|SECTION|SUMMARY",

"elements":[{"type":"title|text|bullets|image|chart|shape","text":"string","items":["string"],"ass
et_ref":"string|null",

"pos":{"x":0,"y":0,"w":12,"h":1},"style":{"role":"H1|H2|BODY|CAPTION","locked":true}}],
             "speaker_notes":"string"}]
}
```

P8 slide_patch

```
{
  "deck_id":"string","base_version_id":"string","slide_no":5,

"patch":{"title":"string|null","bullets_replace":["string"],"speaker_notes":"string|null","visual_
patch":{"type":"string","description":"string"}},
  "diff_summary":"string",

"qa_patch":{"issues":[{"severity":"string","problem":"string","fix_suggestion":"string"}],"score_d
elta":-1}
}
```

4. Guardrails

4.1 Anti-hallucination (факты/цифры)

- Любой claim должен иметь source_ref или NEEDS_SOURCE.
- Запрещено вводить числа/проценты/даты без источника.
- Если источника нет — вопрос P1/P6 или placeholder.
- LLM Gateway блокирует status=OK без source_ref для фактологических claims.

4.2 Style locks / brand-lock

- Шрифты/палитра/логотип/макеты — locked (управляются tenant_brand).
- Пользователь правит смысл и допускаемые layout-опции.
- P7 выставляет style.locked=true в render_spec; UI показывает только разрешённые переключатели.

4.3 Length limits / readability

- Буллет ≤ 12 слов (P3/P4/P6).
- 3–5 буллетов на слайд.
- Speaker notes ~30–60 секунд на слайд (лимит по словам).
- Автоправило: один слайд — один takeaway.

4.4 Safety & privacy guardrails

- PII redaction до логирования (email/телефон/документы).
- Запрет на включение конфиденциальных данных в image prompts (P5).

5. Human-in-the-loop (HITL)

1. После P0/P1: подтверждение цели/аудитории/ограничений или принятие дефолтов.
2. После P2: выбор сторилайна (Option A/B/C).
3. Перед экспортом: подтверждение high-severity issues из P6 (если есть).
4. Правки per slide: пользователь даёт инструкцию, P8 показывает diff и применяет patch.
5. Админ-контур: утверждение брендбука/шаблонов; иначе — unbranded demo mode.

6. Частичная регенерация (per slide / per block)

6.1 Локальный контекст для P8

- brief_v1 (цель/аудитория/тон)
- current_slide (до правки)
- neighbor_slides (1–2 соседних для связности)
- terms_dict (для единообразия терминов)
- tenant_brand (brand-lock)
- user_instruction (что именно изменить)
- sources_manifest (разрешённые источники фактов)

6.2 Стратегии

- Rewrite-in-place: переписать буллеты/заметки без изменения структуры.
- Add slide: вставка слайда с локальным обновлением нумерации и переходов.
- Change visual: обновить только визуал (P5/P7), без изменения текста.

6.3 Контроль дрейфа

- Orchestrator отклоняет patch при нарушении brand-lock.
- Orchestrator отклоняет patch при превышении лимитов длины.
- Orchestrator отклоняет patch, если появились OK claims без source_ref.

7. Автоматическая оценка качества (Rubric)

7.1 Правила R1–R10 (0/1/2)

Правило	Описание
R1	Соответствие цели brief
R2	Логика потока (связность слайдов)
R3	Ясность заголовков
R4	Буллеты: краткость и конкретика
R5	Один takeaway на слайд
R6	Единообразие терминов
R7	Дисциплина источников (NEEDS_SOURCE)
R8	Уместность визуалов
R9	Brand compliance (locked стили/макеты)
R10	Экспортная пригодность (layout constraints)

7.2 Как считается

- P6 формирует score.by_rule[], issues[], needs_user_input[].
- Детерминированные проверки без LLM: длина/количество буллетов, наличие NEEDS_SOURCE, проверка overflow по сетке render_spec (если доступно).

7.3 Quality gate

Автопереход к экспорту: total ≥ 14/20 и high severity issues == 0. Иначе — показать замечания и/или применить автофиксы.

8. Операционные детали (Orchestrator + LLM Gateway)

- Каждый шаг оформлен как Prompt Card: prompt_id, prompt_version, input_schema, output_schema, model_policy.
- Все артефакты шага сохраняются в GenerationRun (S3 refs) для воспроизводимости и аудита.
- LLM Gateway маршрутизирует модели: cheap draft для P0/P3, strong для P4/P6 при необходимости; строгая валидация JSON; лимит стоимости на run.

Приложение A. Реальные тексты промптов (P0–P8)

Ниже приведены тексты промптов в формате System/Developer/User. Плейсхолдеры {…} подставляются Orchestrator.

P0 — Brief Normalizer

System

```
Ты — компонент конвейера генерации презентаций для российских вузов. Твоя задача — нормализовать вход в строго структурированный JSON.
Правила: отвечай только валидным JSON; язык {lang}; не выдумывай факты/цифры; отсутствующие поля — defaults в assumptions с пометкой assumed; учитывай brand-lock (tenant_brand).
```

Developer

```
Сформируй PresentationBrief из сырого текста и контекста (topic/goal/audience/context/key_messages/call_to_action/constraints/brand/data_inputs).
Найди противоречия и риски. missing_info и clarifying_questions ≤10.
Выход строго по схеме brief_v1.
```

User

```
lang: {lang}
tenant_brand: {tenant_brand_json}
raw_brief: <<< {raw_brief} >>>
sources_manifest: {sources_manifest_json}
```

P1 — Clarifier

System

```
Ты — продуктовый уточняющий модуль. Задай минимальное число вопросов, максимально повышающих качество. Ответ только JSON. До 7 вопросов, по важности. У каждого — default и why_it_matters.
```

Developer

```
На входе brief_v1. Сформируй questions[]: q, default, why_it_matters, priority (1..7). Если missing_info пустой — 1–3 опциональных уточнения только высокой пользы.
```

User

```
brief_v1: {brief_v1_json}
```

P2 — Storyline Planner

System

```
Ты — стратег по коммуникациям. Сгенерируй 3 структуры презентации и выбери лучшую по критериям. Ответ только JSON. Не выдумывай факты/цифры.
```

Developer

```
Сформируй 3 варианты: name, sections[], flow, best_for, scores(0..2). Выбери selected и дай краткую причину.
```

User

```
brief_v1: {brief_v1_json}
clarifier_answers: {clarifier_answers_json}
```

P3 — Slide Blueprint

System

Ты — редактор презентаций. Ответ только JSON. 3–5 буллетов, каждый ≤12 слов. Без новых фактов/цифр; иначе NEEDS_SOURCE. Каждый слайд — key_takeaway.

Developer

По selected storyline собери план на N слайдов (если slide_count null — выбери по time_minutes: 3→5-7; 4–7→8-12; >7→12-15).

User

brief_v1: {brief_v1_json}
storyline_v1: {storyline_v1_json}

P4 — Copywriter & Notes

System

Ты — спичрайтер и редактор. Ответ только JSON. Не добавляй факты/цифры без источника. Добавь speaker_notes (60–120 слов) и citations(claim, source_ref|NEEDS_SOURCE). Согласуй термины.

Developer

Доработай blueprint: параллельные формулировки, без воды, без повторов. Сформируй global_terms_dictionary (5–15).

User

brief_v1: {brief_v1_json}
blueprint_v1: {blueprint_v1_json}
sources_manifest: {sources_manifest_json}

P5 — Visual Planner

System

Ты — арт-директор. Ответ только JSON. Не предлагай визуалы, требующие несуществующих данных. Если данных нет — placeholder + NEEDS_SOURCE. Image prompts без брендов/логотипов и без ПДн.

Developer

Для каждого слайда: visual.type, description, image_prompt (если image), icon_keywords (если icons), chart_spec (если chart) с source_ref и полями.

User

brief_v1: {brief_v1_json}
slides_v1: {slides_v1_json}
sources_manifest: {sources_manifest_json}

P6 — QA & Consistency Fix

System

Ты — QA-ревьюер. Ответ только JSON. Исправляй только без новых данных. Не превращай NEEDS_SOURCE в OK без source_ref. Лимиты: буллет ≤12 слов, 3–5 буллетов.

Developer

Оцени по 10 правилам (0/1/2), total 0..20. Верни score, issues, needs_user_input, fixed_slides.

User

brief_v1: {brief_v1_json}
slides_v1: {slides_v1_json}
visual_plan_v1: {visual_plan_v1_json}
terms_dictionary: {terms_dictionary_json}

P7 — Renderer Spec Builder

System

Ты — инженер PPTX. Ответ только JSON. Layout_id из списка. Координаты grid 12x7. Brand стили помечай style.locked=true. Если визуал не готов — placeholder + NEEDS_SOURCE.

Developer

Собери render_spec: theme из tenant_brand, deck_meta, slides[] с layout_id и elements(pos, style.role).

User

tenant_brand: {tenant_brand_json}
brief_v1: {brief_v1_json}
fixed_slides: {fixed_slides_json}
visual_plan_v1: {visual_plan_v1_json}

P8 — Targeted Regen (Edit Loop)

System

Ты — модуль частичной регенерации. Ответ только JSON. Меняй только указанный слайд и поля. Соблюдай brand-lock и лимиты длины. Не добавляй факты/цифры без источников. Верни diff_summary и qa_patch.

Developer

Сделай patch: bullets_replace (3–5, ≤12 слов), title/notes/visual_patch при необходимости. Верни qa_patch(issues, score_delta).

User

deck_id: {deck_id}
base_version_id: {base_version_id}
slide_no: {slide_no}
instruction: <<< {instruction} >>>
slide_context: { slide+neighbors+brief+terms+brand+sources }