System Architecture — AI-сервис генерации презентаций для российских вузов (B2B2C)

Версия: 1.0
Дата: 28.02.2026
Команда: Ангелы Бизнеса

Документ описывает целевую архитектуру MVP сервиса генерации презентаций, ориентированную на SSO, brand-lock, частичную регенерацию, экспорт PPTX/PDF, админ-контур (дашборды/аудит) и комплаенс по ПДн.

Оглавление

1. C4 L1 — Context 4
   1.1 Акторы и внешние системы 4
   1.2 Диаграмма контекста (ASCII) 4
2. C4 L2 — Containers 5
   Web App (UI) 5
      Ответственность: 5
      Ключевые функции: 5
   Orchestrator API (Backend) 5
      Ответственность: 5
      Ключевые функции: 5
   LLM Gateway 5
      Ответственность: 5
   Storage (DB + Object Storage) 5
      Ответственность: 5
   Renderer (PPTX/PDF) 6
      Ответственность: 6
   Asset Service 6
      Ответственность: 6
   Observability (Logs/Metrics/Traces + Audit) 6
      Ответственность: 6
   2.8 Диаграмма контейнеров (ASCII) 7
3. Основные sequence flows 8
   3.1 Flow A — Generate 8
      Принцип anti-hallucination 8
   3.2 Flow B — Edit (частичная регенерация) 9
   3.3 Flow C — Export (PPTX/PDF) 9
4. Выбор технологий (варианты + почему) 10
5. Хранение и версионирование промптов 10
   Хранение 10
   Версионирование 10
   Воспроизводимость 10
   Контроль 10

6. Безопасность (PII/ПДн, секреты, RBAC, audit log) 11
PII/ПДн 11
Secrets 11
RBAC 11
Audit log 11
7. Масштабирование (MVP → growth) 11

1. C4 L1 — Context

1.1 Акторы и внешние системы

Актор/Система	Роль во взаимодействии
Student / Teacher	Создают, правят и экспортируют презентации.
Admin (ВУЗ)	Управляет шаблонами/брендбуком, ролями, отчётами.
Buyer	Оценивает демо/документы для закупки (может совпадать с Admin).
University SSO/IdP	Аутентификация (SAML/OIDC).
LLM Provider(s)	Модели (через LLM Gateway).
Storage (DB + Object Storage)	Хранение сущностей и файлов (источники/экспорты/артефакты).
Observability stack	Метрики, логи, трассировка, аудит.

1.2 Диаграмма контекста

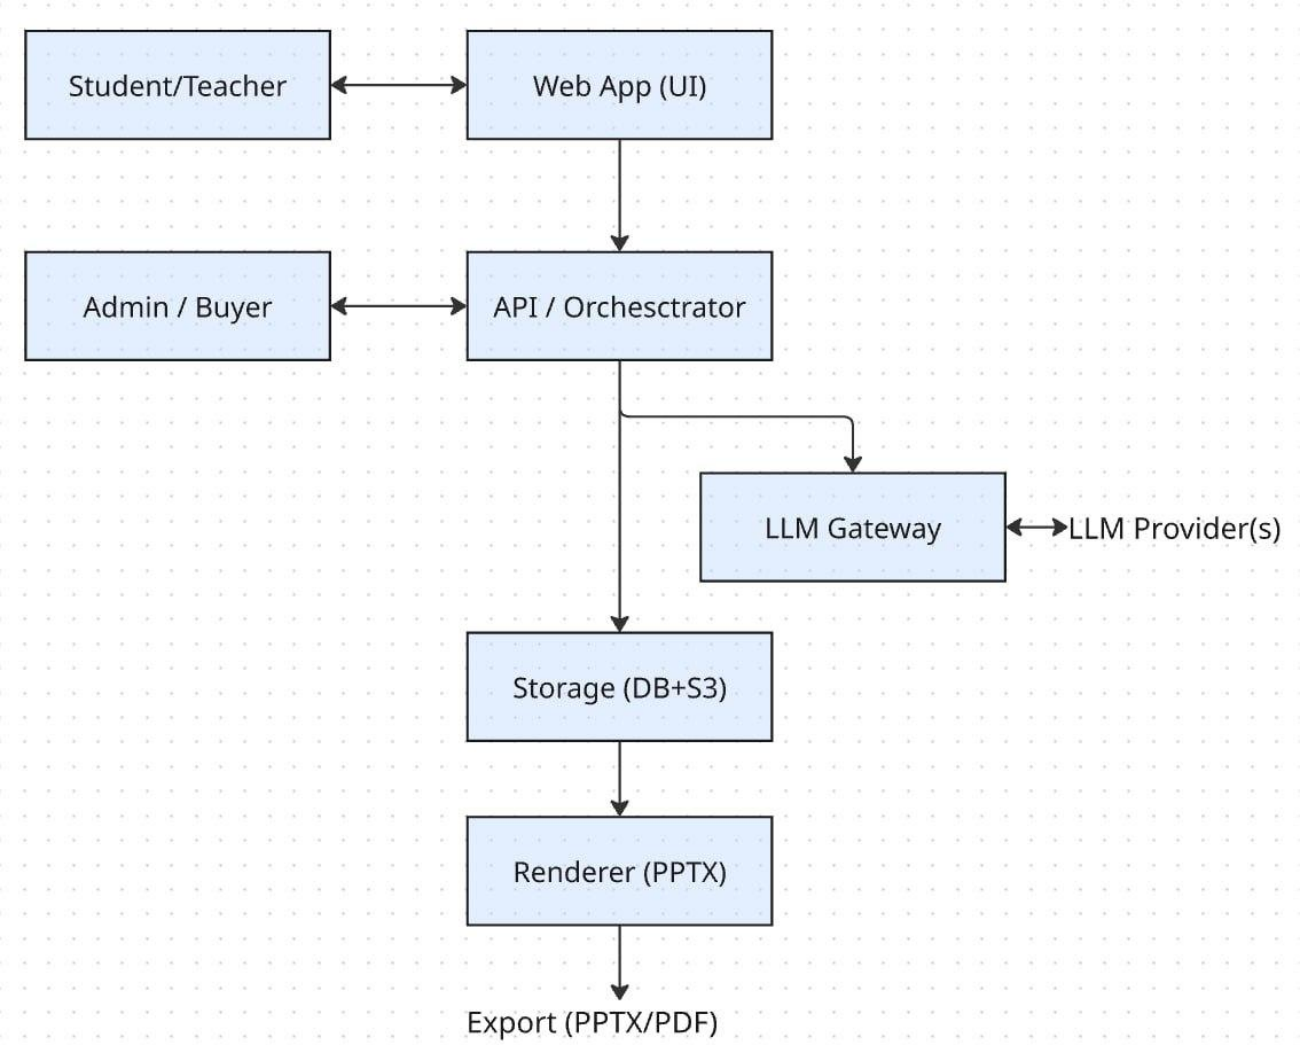

2. C4 L2 — Containers

Web App (UI)

Ответственность:

- SSO-вход, работа с brief, запуск генерации/правок/экспорта, просмотр статусов.
- Редактор слайдов с brand-locked controls.
- Admin-режим: загрузка брендбука/шаблонов, управление орг-структурой, дашборды.

Ключевые функции:

- Draft workspace (deck editor)
- Progress UI (generation/export)
- Admin console (templates, roles, dashboards)

Orchestrator API (Backend)

Ответственность:

- Управляет жизненным циклом Deck / Generation Run / Export Job.
- Оркестрирует пайплайн (normalize → outline → copy → QA → renderSpec).
- Поддерживает частичную регенерацию (per-slide/per-block).
- Применяет политики: brand-lock, лимиты, идемпотентность, ретраи.
- API для UI и интеграция с SSO.

Ключевые функции:

- Auth/RBAC module
- Deck service (CRUD, versions)
- Generation service (runs, steps, caches)
- Export service (jobs, files)
- Admin service (templates, brand tokens)
- Metrics/Audit service

LLM Gateway

Ответственность:

- Единая точка вызова LLM: routing (cheap → strong), fallback.
- Лимиты токенов/стоимости, кэширование.
- Structured output: JSON schema validation.
- Redaction/PII-маскирование в логах.
- Retry/backoff на временные ошибки.

Storage (DB + Object Storage)

Ответственность:

- PostgreSQL: Tenants, Users, Roles, OrgUnits; Decks, Slides, Versions; GenerationRuns/StepResults; Exports/Jobs; AuditEvents; MetricsAgg.

- S3-совместимое хранилище (MinIO): источники, шаблоны/ассеты, экспорты, промежуточные JSON-артефакты.
- Шрифты — только при наличии лицензии и политики вуза.

Renderer (PPTX/PDF)

Ответственность:

- Сборка финального файла по render_spec: применение шаблонов/макетов, размещение элементов, генерация PPTX/PDF.
- Рекомендуемая реализация: stateless workers + очередь задач.

Asset Service

Ответственность:

- Подготовка ассетов: иконки, графики из таблиц (если есть данные), безопасная обработка изображений (resize/compress).
- MVP: каталог иконок + placeholders; графики только из явно переданных таблиц.

Observability (Logs/Metrics/Traces + Audit)

Ответственность:

- Технические метрики: latency, errors, cost.
- Трассировка шагов пайплайна.
- Audit log (неизменяемые события).
- Продуктовые метрики: BPC, activation, exports, time-to-first-deck.

2.8 Диаграмма контейнеров

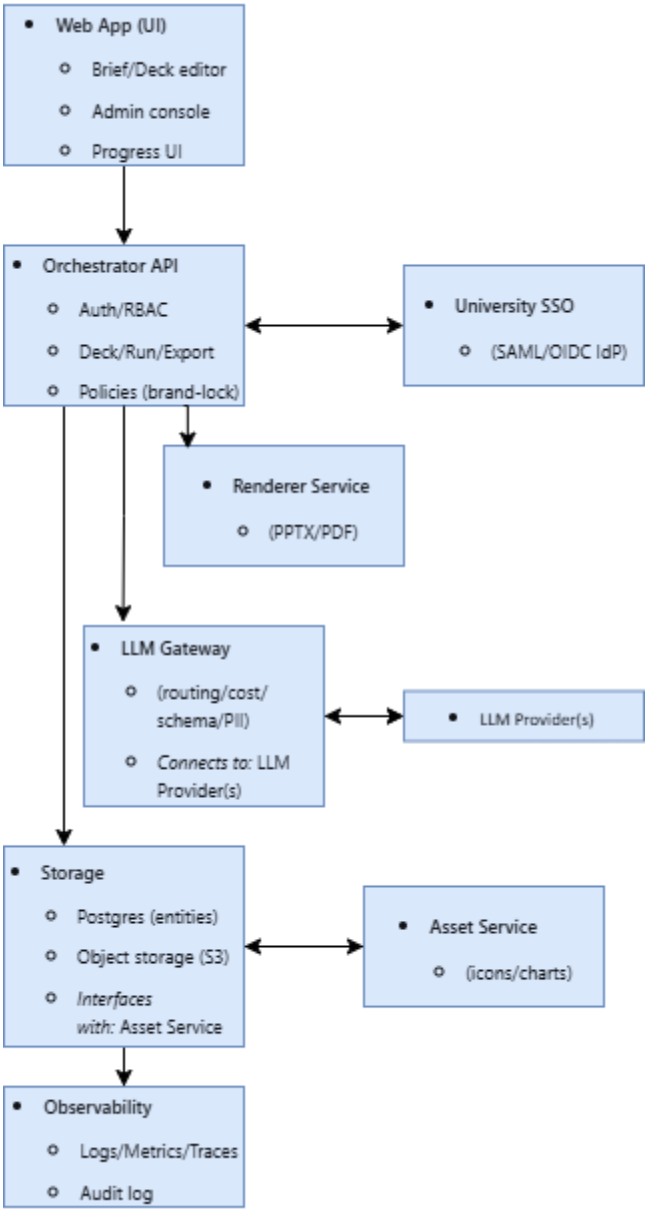

3. Основные sequence flows

3.1 Flow A — Generate

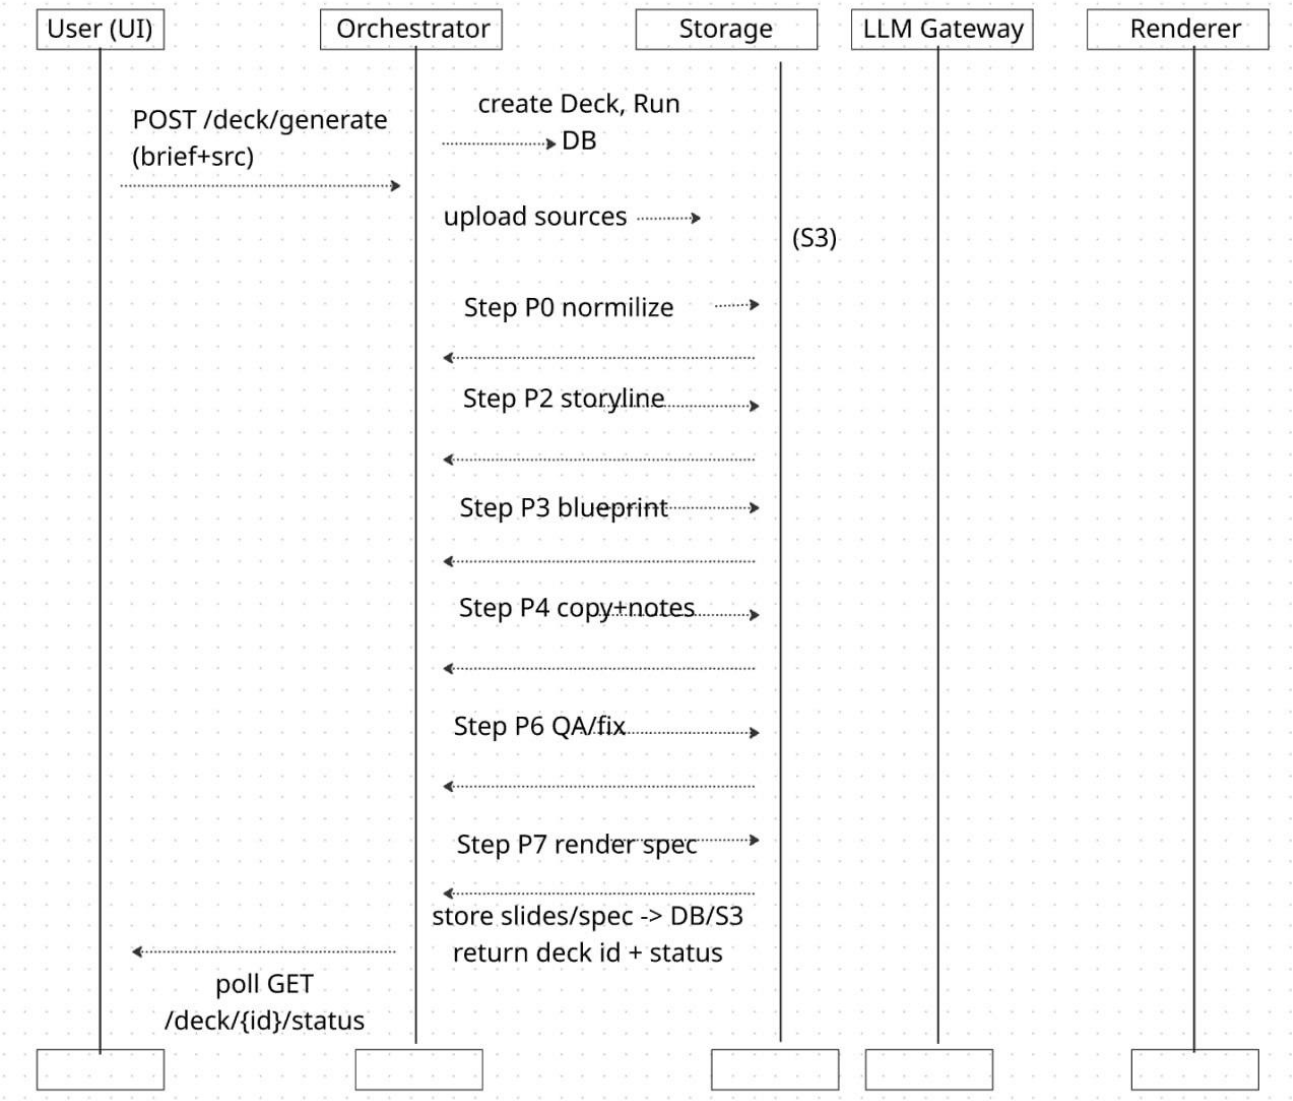

Принцип anti-hallucination

LLM Gateway и Orchestrator запрещают появление «новых фактов»: факты/цифры должны быть из Source, иначе помечаются NEEDS_SOURCE и/или запрашиваются у пользователя.

3.2 Flow B — Edit (частичная регенерация)

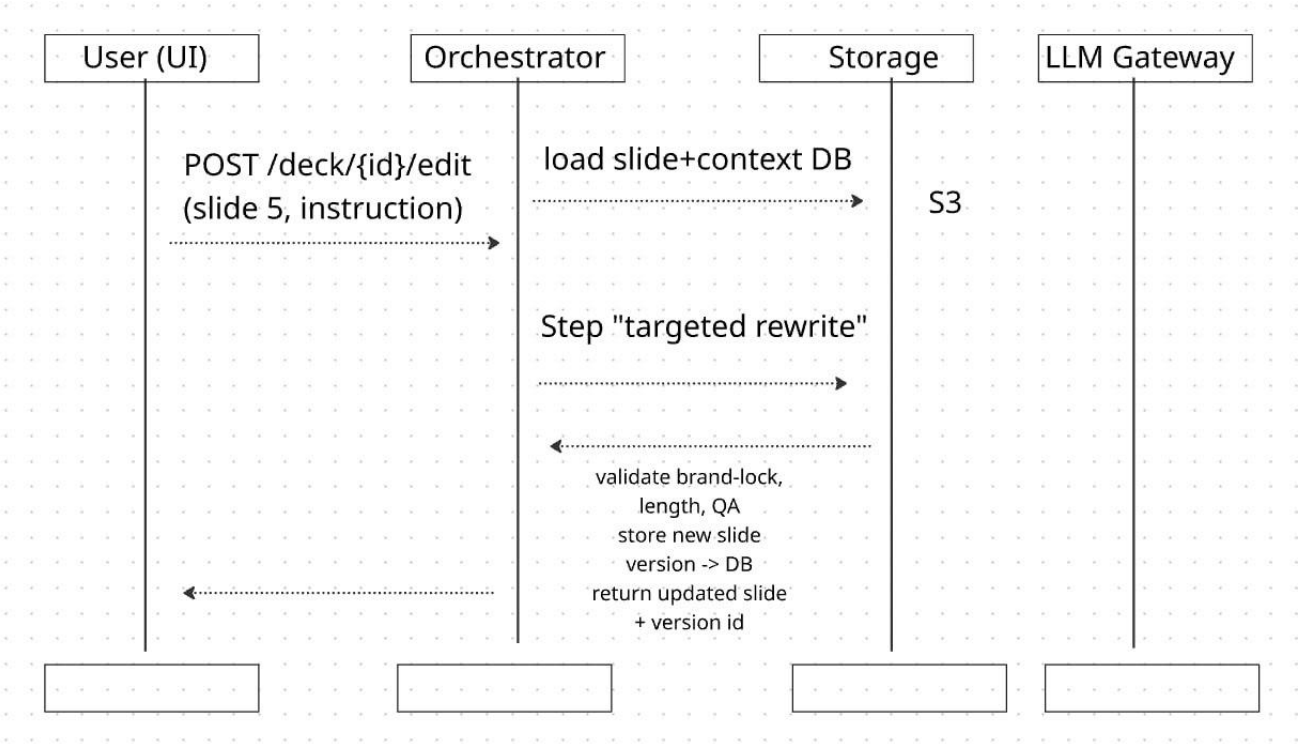

3.3 Flow C — Export (PPTX/PDF)

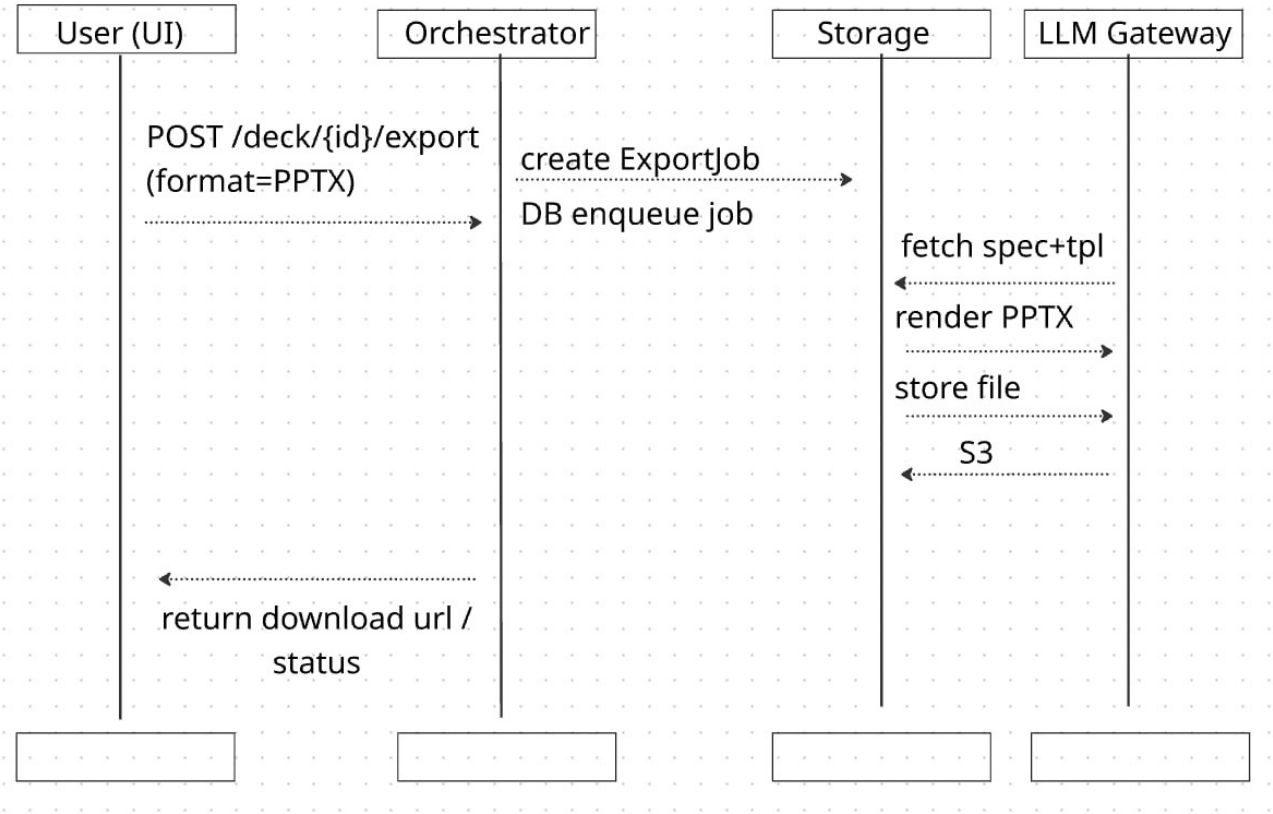

Идемпотентность экспорта: повторный экспорт по той же версии возвращает кэшированный результат.

4. Выбор технологий (варианты + почему)

Компонент	Рекомендуемый выбор / альтернативы
UI	React/Next.js (MVP): быстрый UX, удобный редактор. Альтернатива: Vue/Nuxt.
Orchestrator API	Python/FastAPI (MVP): удобная LLM-оркестрация и валидация схем. Альтернатива: Node.js/NestJS.
Очереди/асинхронные jobs	Redis + Celery/RQ (Python) или BullMQ (Node). Альтернатива: Kafka/RabbitMQ (сложнее для MVP).
Storage	PostgreSQL для сущностей/версий/аудита. S3-compatible (MinIO) для файлов и артефактов.
Renderer	PptxGenJS (Node) — предсказуемая верстка и экспорт. Альтернатива: python-pptx (часто сложнее с layout).
LLM Gateway	Тонкий сервис: routing + schema validation + caching + redaction. Централизует политику качества/стоимости/безопасности.
Observability	Prometheus+Grafana, Loki/ELK, OpenTelemetry. Audit: Postgres + append-only выгрузка (опционально).

5. Хранение и версионирование промптов

Хранение

Промпты — файлы в репозитории (/prompts) + метаданные (id, version, schema).

Версионирование

SemVer для promptset_version; prompt_id@prompt_version для шагов.

Воспроизводимость

GenerationRun сохраняет: promptset_version, prompt_version_per_step, model_id_per_step, input_hash, output_artifacts_ref (S3).

Контроль

JSON schema validation на выходе каждого шага; canary runs на тест-брифах при изменениях.

6. Безопасность (PII/ПДн, секреты, RBAC, audit log)

PII/ПДн

- Минимизация атрибутов (id, role, org_unit).
- Redaction ПДн в логах шагов LLM.
- Настраиваемая политика хранения данных per-tenant.

Secrets

- Secrets Manager (Vault/KMS/аналог).
- Запрет логирования секретов; доступ через сервисные аккаунты.

RBAC

- Роли: Student, Teacher, Admin, Buyer.
- Ограничения по org_unit и tenant isolation.

Audit log

- События: login, generate_start/finish, edit, export, template_update, role_change.
- Append-only хранение: Postgres + (опц.) write-once bucket/таблица без UPDATE прав.

7. Масштабирование (MVP → growth)

- Renderer и LLM-пайплайн масштабируются горизонтально воркерами.
- LLM Gateway централизует лимиты стоимости и качество.
- Multi-tenant изоляция через tenant_id на всех сущностях и отдельные префиксы/buckets в S3.

Связанные документы: PRD, SRS, Prompt Architecture, API Spec, QA Plan.